


LDA



$$W = \{w_1, w_2, \dots, w_N\}$$

$$Z = \{z_1, z_2, \dots, z_M\}$$

• 简化版 - 单文档 - 即  $M=1$


**联合:**

$$P(\theta, z, w | \alpha, \beta) = P(\theta | \alpha) \cdot \prod_{n=1}^N P(z_n | \theta) \cdot P(w_n | z_n, \beta)$$

其中  $w$  是 observed, 其余是 latent


loglik:  $P(\theta, z | w, \alpha, \beta)$

• 由 mean-field  $q(z) = \prod_{i=1}^M q_i z_i$  ( $i$  前是用來表示宏觀的)



$$P(x) = \frac{1}{2} \varphi_{12}(x_1, x_2) \varphi_{23}(x_2, x_3) \varphi_{34}(x_3, x_4)$$

$$q(\theta, z | \alpha, \beta) = q(\theta | \alpha) \prod_{n=1}^N q(z_n | \beta_n)$$



$\beta$ : Dir 分布

$\beta_n: \{\beta_1, \beta_2, \dots, \beta_N\}$  独立分布

故  $\theta$  和  $z$  独立, 而  $z$  和  $w$  不独立

↓

这个就是构造的  $q$  这边，用表达似然函数  $P(\theta, z|w, \gamma, \varphi)$

$$\log p(x) = E_{LB} + KL \text{ divergence}$$

$$= E_{q(x)} \log \frac{p(x, y)}{q(x)} + E_{q(x)} \log \frac{q(x)}{p(y|x)}$$

$\xleftarrow{\text{构造的 } q(x)}$        $\xleftarrow{\text{似然}}$

从而， $E_{LB}$ :

$$L(\gamma, \eta, \theta, z) = E_{q(\theta, z|y, \eta)} \log \frac{p(\theta, z, w|\alpha, \varphi)}{q(\theta, z|y, \eta)}$$

$$= E_q \log p(\theta, z, w|\alpha, \varphi) - E_q \log q(\theta, z|y, \eta)$$

展开：

$$L(\gamma, \eta, \theta, z) = E_q \log p(\theta|\alpha) + E_q \log p(z|\theta)$$

$$+ E_q \log (w|z, \varphi) - E_z \log p(z|\eta) - E_q \log p(z|\eta)$$

$z$  和  $w$  都是 vector

△ 该式融合了参数  $\alpha, \beta$  和变量  $\varphi$  和  $\eta$

对  $L(\gamma, \eta, \theta, z) - 2R$  一项研究：

第一项：  $E_q \log p(\theta|\alpha)$

$p(\theta|\alpha)$  服从 Dir 分布

$$p(\theta|\alpha) = \frac{P\left(\sum_{i=1}^K \theta_i\right)}{\prod_{i=1}^K P(\theta_i)} \prod_{i=1}^K \theta_i^{\alpha_i - 1}$$

$$\log p(\theta | \alpha) = \log \left[ P\left(\sum_{k=1}^K \alpha_k\right)\right] - \sum_{k=1}^K \log P(\alpha_k) + \sum_{k=1}^K (\alpha_{k-1}) \log \theta_i$$

$$E_q \log p(\theta | \alpha) = E_q \left( \log \left[ P\left(\sum_{k=1}^K \alpha_k\right)\right] - \sum_{k=1}^K \log P(\alpha_k) \right)$$

$$+ E_q \left( \sum_{k=1}^K (\alpha_{k-1}) \log \theta_k \right) \quad q \rightarrow q(\theta, z | \gamma, \varphi)$$

只有该次有θ

$$= \log \left[ P\left(\sum_{k=1}^K \alpha_k\right)\right] - \sum_{k=1}^K \log P(\alpha_k)$$

$$+ \sum_{k=1}^K (\alpha_{k-1}) E_q \log \theta_k$$

公式:  $E_{q(\theta | \alpha)} \ln(\theta_i) = \psi(\gamma_i) - \psi\left(\sum_{j=1}^K \gamma_j\right)$

where  $\psi$  is digamma func.

易混:

由公式:

$$E_{q(\theta | \alpha)} \log \theta_k = \psi(\gamma_k) - \psi\left(\sum_{l=1}^K \gamma_l\right) \quad \begin{matrix} P(\theta | \alpha) \\ q(\theta | \gamma) \end{matrix}$$

$$\therefore E_q \log P(\theta | \alpha) = \log \left[ P\left(\sum_{k=1}^K \alpha_k\right)\right] - \sum_{k=1}^K \log P(\alpha_k)$$

$$+ \sum_{k=1}^K (\alpha_{k-1}) \left[ \psi(\gamma_k) - \psi\left(\sum_{l=1}^K \gamma_l\right) \right]$$

其中,  $\alpha_k, \gamma_k$  分别是第  $k$  个文档的 dir<sup>参数</sup>

第二项:  $E_q \log P(Z | \theta)$

$$E_q \log P(Z | \theta) = \sum_{n=1}^N E_q \log P(z_n | \theta)$$

$$= \sum_{n=1}^N E_{q(\theta, z | \gamma, \varphi)} \log P(z_n | \theta) \quad z_n \sim \text{multi}(\theta)$$

$$\begin{aligned}
&= \sum_{n=1}^N \sum_{k=1}^K q(\mathbf{z}_n | \varphi) E_{q(\theta | \mathbf{z})} \log \theta_k \quad \theta_k \stackrel{\text{def}}{=} \left( \frac{\sum_{n=1}^N \eta_{nk}}{\sum_{k=1}^K \eta_{nk}} \right) \\
&= \sum_{n=1}^N \sum_{k=1}^K q(\mathbf{z}_{nk} | \varphi) \left[ q(\mathbf{z}_k) - H\left(\sum_{k=1}^K \eta_{nk}\right) \right] \quad E(x) = \sum_{k=1}^K p_k x_k \\
&= \sum_{n=1}^N \sum_{k=1}^K \eta_{nk} \left[ q(\mathbf{z}_k) - H\left(\sum_{k=1}^K \eta_{nk}\right) \right] \quad \mathbf{z}_n \sim \text{multi}(\theta) \\
&\Rightarrow \theta \stackrel{\text{def}}{=} \eta
\end{aligned}$$

$\eta_{nk}$ : 文档第  $n$  个单词由第  $k$  个话题产生的概率

第 3 项:  $E_q \log(W | \mathbf{z}, \varphi)$

$$\begin{aligned}
&= \sum_{n=1}^N E_q \log(W | \mathbf{z}_n, \varphi) \quad q \rightarrow q(\theta, \varphi | \mathbf{z}, \varphi) \\
&= \sum_{n=1}^N E_{q(\mathbf{z}_n | \eta)} \log(W | \mathbf{z}_n, \varphi) \\
&= \sum_{n=1}^N \sum_{k=1}^K q(\mathbf{z}_{nk} | \eta) \log(W | \mathbf{z}_{nk}, \varphi) \quad E(x) = \sum_{k=1}^K x_k p_k \\
&= \sum_{n=1}^N \sum_{k=1}^K \sum_{v=1}^V \eta_{nk} w_n^v \log \varphi_{kv}
\end{aligned}$$

式中  $\eta_{nk}$  表示文档第  $n$  个位置的单词由第  $k$  个话题产生的概率,  $w_n^v$  在第  $n$  个位置的单词是单词集合的第  $v$  个单词时取值为 1, 否则取值为 0,  $\varphi_{kv}$  表示第  $k$  个话题生成单词集合中第  $v$  个单词的概率。

第4项:  $E_q \log p(\theta | \gamma)$

$$E_q[\log q(\theta | \gamma)] = \log \Gamma\left(\sum_{l=1}^K \gamma_l\right) - \sum_{k=1}^K \log \Gamma(\gamma_k) + \sum_{k=1}^K (\gamma_k - 1) \left[ \Psi(\gamma_k) - \Psi\left(\sum_{l=1}^K \gamma_l\right) \right] \quad (20.54)$$

式中  $\gamma_k$  表示第  $k$  个话题的狄利克雷分布参数。

第5项:  $E_q \log p(z | \eta)$

$$\begin{aligned} &= \sum_{n=1}^N E_{q(z_n | \eta)} \log p(z_n | \eta) \\ &= \sum_{n=1}^N \sum_{k=1}^K q(z_{nk} | \eta) \log p(z_{nk} | \eta) \\ &= \sum_{n=1}^N \sum_{k=1}^K \eta_{nk} \log \eta_{nk} \end{aligned}$$

联合

$$\begin{aligned} L(\gamma, \eta, \alpha, \varphi) &= \log \Gamma\left(\sum_{l=1}^K \alpha_l\right) - \sum_{k=1}^K \log \Gamma(\alpha_k) + \sum_{k=1}^K (\alpha_k - 1) \left[ \Psi(\gamma_k) - \Psi\left(\sum_{l=1}^K \gamma_l\right) \right] + \\ &\quad \sum_{n=1}^N \sum_{k=1}^K \left[ \Psi(\gamma_k) - \Psi\left(\sum_{l=1}^K \gamma_l\right) \right] + \\ &\quad \sum_{n=1}^N \sum_{k=1}^K \sum_{v=1}^V \eta_{nk} w_n^v \log \varphi_{kv} - \\ &\quad \log \Gamma\left(\sum_{l=1}^K \gamma_l\right) + \sum_{k=1}^K \log \Gamma(\gamma_k) - \sum_{k=1}^K (\gamma_k - 1) \left[ \Psi(\gamma_k) - \Psi\left(\sum_{l=1}^K \gamma_l\right) \right] - \\ &\quad \sum_{n=1}^N \sum_{k=1}^K \eta_{nk} \log \eta_{nk} \end{aligned} \quad (20.47)$$

式中  $\Psi(\alpha_k)$  是对数伽马函数的导数, 即

$$\Psi(\alpha_k) = \frac{d}{d\alpha_k} \log \Gamma(\alpha_k) \quad (20.48)$$

$$q \rightarrow q(\theta, z | \gamma, \eta)$$

$\theta \sim \text{Dir}(\delta)$  类似假设

# VI EM algorithm

在E步骤，我们使用近似于原始LDA后验分布的变分分布去寻找变分参数（variational parameter）的最优解。在M步骤，使用~~E~~步骤中已获得的变分参数估计去估计（比如极大似然估计（parameter estimate））原模型参数（model parameter），从而进一步最大化模型的下界（bound）。

## 算法 overview:

### 算法 20.5 (LDA 的变分 EM 算法)

输入：给定文本集合  $D = \{w_1, \dots, w_m, \dots, w_M\}$ ；

输出：变分参数  $\gamma, \eta$ , 模型参数  $\alpha, \varphi$ ；

交替迭代 E 步和 M 步，直到收敛。

#### (1) E 步

固定模型参数  $\alpha, \varphi$ , 通过关于变分参数  $\gamma, \eta$  的证据下界的最大化，估计变分参数  $\gamma, \eta$ 。具体见算法 20.4。

#### (2) M 步

固定变分参数  $\gamma, \eta$ , 通过关于模型参数  $\alpha, \varphi$  的证据下界的最大化，估计模型参数  $\alpha, \varphi$ 。具体算法见式 (20.63) 和式 (20.67)。

根据变分参数  $(\gamma, \eta)$  可以估计模型参数  $\theta = (\theta_1, \dots, \theta_m, \dots, \theta_M), z = (z_1, \dots, z_m, \dots, z_M)$ 。

### 算法 9.1 (EM 算法)

输入：观测变量数据  $Y$ , 隐变量数据  $Z$ , 联合分布  $P(Y, Z|\theta)$ , 条件分布  $P(Z|Y, \theta)$ ；

输出：模型参数  $\theta$ 。

(1) 选择参数的初值  $\theta^{(0)}$ , 开始迭代；

(2) E 步：记  $\theta^{(i)}$  为第  $i$  次迭代参数  $\theta$  的估计值，在第  $i+1$  次迭代的 E 步，计算

$$Q(\theta, \theta^{(i)}) = E_Z[\log P(Y, Z|\theta)|Y, \theta^{(i)}] \\ = \sum_Z \log P(Y, Z|\theta)P(Z|Y, \theta^{(i)}) \quad (9.9)$$

这里， $P(Z|Y, \theta^{(i)})$  是在给定观测数据  $Y$  和当前的参数估计  $\theta^{(i)}$  下隐变量数据  $Z$  的条件概率分布；

(3) M 步：求使  $Q(\theta, \theta^{(i)})$  极大化的  $\theta$ , 确定第  $i+1$  次迭代的参数的估计值  $\theta^{(i+1)}$

$$\theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)}) \quad (9.10)$$

(4) 重复第 (2) 步和第 (3) 步，直到收敛。

式 (9.9) 的函数  $Q(\theta, \theta^{(i)})$  是 EM 算法的核心，称为  $Q$  函数 ( $Q$  function)。

## E 步 算法 overview:

### [UW 章的平均场中有备注算法)

#### 算法 20.4 (LDA 的变分参数估计算法)

(1) 初始化：对所有  $k$  和  $n$ ,  $\eta_{nk}^{(0)} = 1/K$

(2) 初始化：对所有  $k$ ,  $\gamma_k = \alpha_k + N/K$

(3) 重复

(4) 对  $n = 1$  到  $N$

(5) 对  $k = 1$  到  $K$

$$(6) \eta_{nk}^{(t+1)} = \varphi_{kv} \exp \left[ \Psi(\gamma_k^{(t)}) - \Psi \left( \sum_{l=1}^K \gamma_l^{(t)} \right) \right]$$

(7) 规范化  $\eta_{nk}^{(t+1)}$  使其和为 1

$$(8) \gamma^{(t+1)} = \alpha + \sum_{n=1}^N \eta_n^{(t+1)}$$

(9) 直到收敛

对于 GMM 来说，后验  $P(Z|Y, \theta^{(i)})$  是可求的，但对于 LDA 来说，后验不可求，用构造的子逼近真实后验  $P$ 。

由参数  $\gamma, \eta$  决定，E 步估算出

子  $\eta, \gamma$  具体方法：写出联合，固定模型参数，引进 aggregation 子。

推导：

$L(\gamma, \eta, \alpha, \varphi)$  包含  $\eta$  的项：第 2, 3, 分项

$$L(\gamma) = \sum_{n=1}^N \sum_{k=1}^K \eta_{nk} \left[ \Psi(\gamma_k) - \Psi \left( \sum_{l=1}^K \gamma_l \right) \right] + \sum_{n=1}^N \sum_{k=1}^K \sum_{v=1}^V \eta_{nk} w_n^v \log \varphi_{kv} + \sum_{n=1}^N \sum_{k=1}^K \eta_{nk} \log \eta_{nk}$$

$\eta_{nk}$ : 在  $n$  个位置的单词是由第  $k$  个语题生成的概率

Besides. 有约束如下:  $\sum_{k=1}^K \eta_{nk} = 1$

$\therefore$  Lagrangian:

$$L(\eta) = \underbrace{\eta_{nk} [\psi(\gamma_k) - \psi\left(\sum_{e=1}^k \gamma_e\right)}_2 + \underbrace{\eta_{nk} \log \varphi_{kv} - \eta_{nk} \log \lambda}_{3} + \lambda_n \left( \sum_{k=1}^K \eta_{nk} - 1 \right)_5$$

$\varphi_{kv}$ : 在第  $n$  位置由第  $k$  个语题生成第  $v$  个单词的概率